SPARK Workflow

Technischer Produktsteckbrief

Offene, modulare Anwendung für KI-gestützte Planungs- und Genehmigungsverfahren

Was ist SPARK Workflow?

SPARK Workflow ist eine containerisierte, plattformunabhängige Open-Source-Anwendung zur Unterstützung digitaler Planungs- und Genehmigungsverfahren. Die Anwendung besteht aus modularen KI-Komponenten, die über eine zentrale Workflow-Engine (Temporal) gesteuert werden. Der Mensch prüft die KI-Ergebnisse (Human-in-the-Loop) und behält die Letztentscheidung.

Typische Aufgaben der KI-Module: Anonymisierung, Inhaltsextraktion, Vollständigkeits- und Plausibilitätsprüfung, Normenermittlung und -bewertung, Einwendungsmanagement.

Architektur im Überblick

- Containerisierte Architektur aus Backend, KI-Modulen und Datenbankdiensten
- Dreischichtige Architektur (Dienst-, Orchestrierungs- und KI-Modulebene)
- Dokumentierte HTTP-Schnittstellen (OpenAPI)
- Eigenständige Anwendung für Kubernetes-Infrastrukturen (Public Cloud, Private Cloud, On-Premise)
- Open Source unter EUPL 1.2

Nutzen und Aufwand

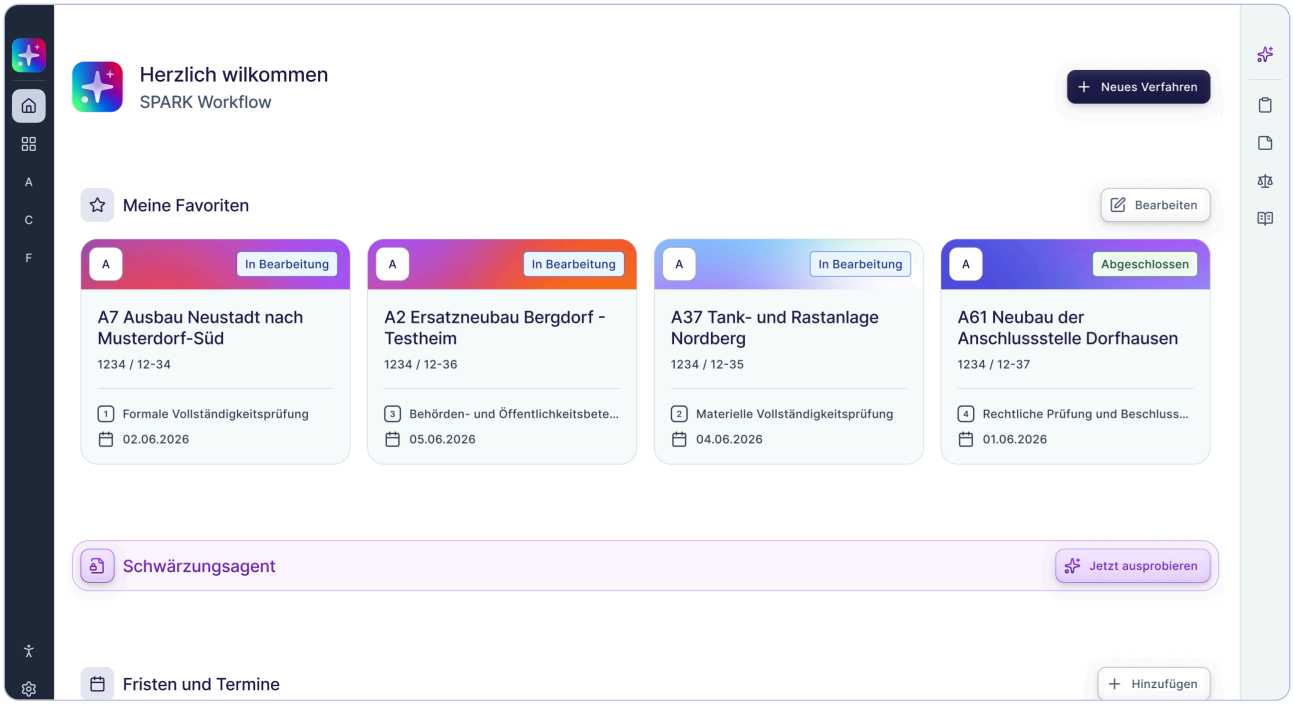
- Weitere KI-Module lassen sich als eigenständige Bausteine ergänzen
- Betreiber stellen Kubernetes, Identitätsdienst und Sprachmodelle bereit

KI-Architektur & Datenverarbeitung

- Offene Modelle: gpt-oss, Qwen, Gemma (Text), BGE-M3 (Einbettungen), LightOnOCR (OCR)
- Dokumentenvorverarbeitung mit Docling (inkl. OCR)
- Vektordatenbank Qdrant für Textfragmente und Vektordarstellungen
- Sprach-, Einbettungs- und OCR-Modelle über ein LLM-Gateway (OpenAI-kompatible API)
- Modelle über Konfiguration und Gateway austauschbar

Nutzen und Aufwand

- Fokus auf Orchestrierung der KI statt Modelloptimierung
- Kein eigenes Modelltraining erforderlich



Beispielansicht der Anwendung

Workflow-Orchestrierung

- Zentrale Workflow-Engine: Temporal
- Prozesslogik als Programmcode in TypeScript (Orchestrierung) und Python (KI-Module)
- Asynchrone Verarbeitung über Workflows

Nutzen und Aufwand

- Nachvollziehbarkeit durch Workflow-Historie
- Ausgelegt für lang laufende, mehrstufige Prozesse

Betrieb & Skalierung

- Bereitstellung und Konfiguration über Helm-Charts
- Skalierbar über Kubernetes-Autoskalierung
- Drei Node-Pools: Default (mind. 3 VMs), Large (Qdrant), GPU (Docling)
- Jede Behörde erhält eine eigene Installation
- On-Premise-Betrieb möglich

Nutzen und Aufwand

- Horizontale Skalierung bei steigender Last

Sicherheit & Zugriff

- Zentrale Anmeldung über einen Identitätsdienst (OpenID Connect, Referenz: Keycloak)
- Zweistufige Rechteverwaltung: Systemrollen im Identitätsdienst, Projektrollen in der Anwendung (SpiceDB)
- Geschützte Dienste: verschlüsselte Kommunikation (mTLS) und zentrale Verwaltung von Zugangsdaten (Referenzplattform: Istio, HashiCorp Vault)
- Virenprüfung hochgeladener Dateien (ClamAV); Änderungen durch Nutzer und KI bleiben nachvollziehbar (Audit-Log, Versionshistorie)

Nutzen und Aufwand

- Sicherheit über zentrale Anmeldung und Rechteverwaltung
- Mehrere Sicherheitskomponenten erhöhen den Integrationsaufwand

Tech-Stack

Frontend	React, TypeScript
Backend	Bun, Elysia, Python, FastAPI
Workflow	Temporal
Datenhaltung	PostgreSQL, Qdrant, S3-Speicher, Redis
KI	LiteLLM, Docling
Sicherheit	Keycloak, SpiceDB, ClamAV
Betrieb	Kubernetes, Helm

Beispielhafte Anforderungen für vier Behörden mit je ca. 40 Planfeststellungsverfahren pro Jahr

4 Nodes inkl. Qdrant-Node	**16** CPU je Node, 5. Generation Intel Xeon Scalable	**64** GB RAM je Node	**20** GPU 2 × L4 für Docling, 18 × H200 für Inferenz

Finanziert aus dem Klima- und Transformationsfonds des

Bundesministerium für Digitales und Staatsmodernisierung
Bundesministerium für Wirtschaft und Energie

Herausgeber: Bundesministerium für Digitales und Staatsmodernisierung (BMDS) · Lizenz: EUPL 1.2
Quellcode und Dokumentation: gitlab.opencode.de/bmds/planungs-und-genehmigungsbeschleunigung/spark-workflow
Weitere Informationen: bmds.bund.de/themen/kuenstliche-intelligenz/ki-in-der-verwaltung/spark