SPARK

SPARK Workflow – Technische Architektur

Modulare Architektur von KI-Komponenten mit zentraler Workflow-Engine

Was ist SPARK Workflow?

SPARK Workflow ist eine containerisierte, plattformunabhängige Open-Source-Applikation zur Unterstützung digitaler Planungs- und Genehmigungsprozesse.

Die Lösung setzt auf eine modulare Architektur verschiedener KI-Komponenten die über eine zentrale Workflow-Engine (Temporal) orchestriert werden. Der Mensch bleibt dabei durch das Human-in-the-Loop-Prinzip an jeder Prozessstelle eingebunden und behält die Letztentscheidung. Eine flexible Integration (einzelner Module) in bestehende digitale Lösungen über standardisierte Schnittstellen ist möglich (z. B. Fachplanungsportal, DiPlan).

Architektur & Plattform

- Containerisierte Service-Architektur mit ausführlicher Schnittstellendokumentation
- Dreischichtige Architektur (Service Layer, Orchestration Layer, AI Module Layer)
- Standalone-Applikation
- Auf jeder Kubernetes-Infrastruktur lauffähig (Public Cloud, Private Cloud, On-Premise)
- Vollständig Open Source (EUPL 1.2)

Einordnung zum Betrieb

- Hohe Flexibilität und Erweiterbarkeit

Workflow-Orchestrierung

- Zentrale Workflow-Engine: Temporal
- Code-basierte Prozesslogik (Python)
- Asynchrone Verarbeitung über Workflows
- Event-basierter Datenfluss

Einordnung zum Betrieb

- Nachvollziehbarkeit durch Workflow-Historie
- Geeignet für komplexe, langlaufende Prozesse mit mehreren Zuständen

KI-Architektur & Datenverarbeitung

- Einsatz von Open-Source-Sprachmodellen (Qwen, Gemma, gpt-oss)
- Vektordatenbank Qdrant für Speicherung von Textfragmenten und Vektorrepräsentationen
- Routing von Inferenz-Anfragen über ein LLM-Gateway (OpenAI-kompatible API)
- KI-Modelle sind austauschbar

Einordnung zum Betrieb

- Fokus auf Orchestrierung der KI statt Modelloptimierung
- Schnelle Inbetriebnahme ohne eigenes Modelltraining

Betrieb & Skalierung

- Einfache Bereitstellung und Konfiguration über Helm-Charts
- Drei dedizierte Node Pools: Default Node Pool (mind. 3 VMs), Large Node Pool für Qdrant, GPU Node Pool für Docling
- Mandantentrennung über separate Deployments
- On-Prem-Betrieb und Anbindung von externen Modellanbietern möglich

Einordnung zum Betrieb

- Hohe Skalierbarkeit
- Betriebskomplexität steigt mit Anzahl der Mandanten

Sicherheit & Zugriff

- Authentifizierung und Autorisierung über Keycloak (OpenID Connect / OAuth 2.0)
- Zweistufiges Rollen- und Rechtekonzept: Systemrollen im OIDC-Identitätsanbieter, Verfahrensrollen in der Applikation über SpiceDB
- mTLS-gesicherte Service-Kommunikation über ein Service-Mesh (z. B. Istio)
- Zentrales Secrets-Management (z. B. über HashiCorp Vault)
- Sicherheit wird auf Infrastruktur- und Applikationsebene mehrschichtig umgesetzt
- Zentrale Protokollierung

Einordnung zum Betrieb

- Hohe betriebliche Sicherheit durch zentrale Authentifizierung und kontrollierte Zugriffskontrolle
- Erhöhter Integrations- und Konfigurationsaufwand durch mehrere aufeinander abgestimmte Sicherheitskomponenten

Tech-Stack

Frontend

React, TS

Backend

FastAPI, Python Microservices

Workflow

Temporal

Datenhaltung

PostgresSQL (pro Service), Redis (Caching), S3-kompatibler Speicher, Qdrant (Vektordatenbank)

Künstliche Intelligenz

LLMs über einen LLM-Proxy

Betrieb

kubernetes

Beispielhafte Anforderungen zur Nutzung für vier Behörden mit dedizierter Hardware (bei jeweils ca. 40 Planfeststellungsverfahren pro Jahr)

4 Nodes (inkl. Qdrant-Node)	**16** CPU je Node (5. Generation Intel Xeon Scalable)	**64 GB** RAM	**20 x H200** GPU (2 x Docling Typ L4, 18 x für Inferenz über dedizierte Hardware)